

차원 축소

Dimension Reduction


Agenda

- 01 차원 축소란
- 02 차원 축소의 필요성
- 03 차원 축소 방법

1. 차원축소란

차원축소

Techniques 데이터를 고차원에서 저차원으로 변환시키는 방법. 해당 과정을 통해 데이터의 일부 즉, 의미있는 특성을 보존하도록 하는 과정을 의미




2. 차원축소의 필요성

2. 차원축소의 필요성

고차원 데이터

고차원 데이터란, 많은 변수를 가진 데이터
이미지 데이터, 텍스트 데이터, 유전체 데이터, 마케팅 및 금융 데이터




차원의 저주

비효율성



더 많은 차원은 더 많은 계산을
필요로 하므로, 모델 훈련 및 예측
시간이 길어짐

과적합



차원이 늘어나면서 모델이
노이즈까지 정답으로 오해하여,
훈련 데이터는 완벽하게 설명하지만 테스트 데이터
에 대한 예측력이 떨어지는 상태 발생

데이터 희소성 증가

1.0	0	5.0	0	0	0	0	0
0	3.0	0	0	0	0	11.0	0
0	0	0	0	9.0	0	0	0
0	0	6.0	0	0	0	0	0
0	0	0	7.0	0	0	0	0
2.0	0	0	0	0	10.0	0	0
0	0	0	8.0	0	0	0	0
0	4.0	0	0	0	0	0	12.0

고차원 공간에서는 데이터가 희소
해지며, 데이터 포인트 사이의 거리
가 서로 멀어지는 경향 존재

차원의 저주 해결

데이터의 양을 늘리기
(샘플의 수를 늘리기)

차원축소

3. 차원축소 방법

3. 차원축소 방법

1

Feature selection 특징선택

필요한 변수만 선택
필요한 변수라는 기준은 각 방법마다 다를 수 있음

2

Feature Extraction 특징추출

중요한 특징만을 고려하여 다른 변수로 재구성

Wrapper method	실제 모델을 학습 시킨 후 그 결과를 바탕으로 변수를 평가함 반복적으로 모델을 학습시켜 최적의 조합을 찾음 전진, 후진, 단계적
Filter method	통계적 특정 지표를 사용하여 데이터의 통계적 특성만으로 변수를 선택함 모델을 학습하기 전에 필터링 통계적 특정 지표를 기준으로 도움이 되지 않는 피쳐들을 걸러냄 분산기반, 상관계수, 카이제곱검정

PCA	선형데이터 대상, 비지도 학습 방식 주로 일반적인 차원축소, 노이즈 제거에 이용
MDS	선형 데이터 대상 주로 추천시스템에 이용 (희소행렬 다루기)
t-SNE	비선형 데이터 대상, 비지도 방식 주로 시각화를 위해 사용됨
LDA	선형데이터 대상, 지도 방식 분류 성능 향상을 위해 사용됨

특징선택

Filter method

분산기반선택	분산이 낮은 변수를 제거
상관계수	타겟 변수와 상관관계가 높은 변수선택
카이제곱검정	범주형 데이터 간의 독립성 검정

Wrapper method

전진	변수가 없는 상태에서 하나씩 추가하여 성능 확인
후진	모든 변수에서 시작해 기여도가 낮은 변수를 제거
단계적	전진선택과 후진선택을 병행하며 최적 조합 탐색

3. 차원축소 방법

PCA

분산보존

주성분

개수 선택

어떻게 투영시킬 것인가? 라는 질문에 대한 답
분산이 최대한 보존되는 축을 선택하는 것이
정보가 가장 적게 손실되므로 합리적
데이터의 단위가 다르면 분산의 크기가 왜곡될 수 있으므로
스케일링 필수

분산을 최대한 보존하는 축을 찾는 것은
주성분의 개념과 연결됨
1. 분산이 최대인 축 찾기
2. 첫번째 축에 직교하고 남은 분산을 최대한 보존하는
두번째 축 찾기
이렇게 i 번째 축을 연속적으로 찾게 되는데,
이때의 i 번째 축을 i 번째 주성분이라고 부름


데이터 분석의 목적과 설계에 따라 달라짐
1. 주성분으로 설명되는 분산의 비율이 **95% 이상**
2. **시각적 방법**
3. **하이퍼파라미터**처럼 사용 가능 (차원의 수를

PCA 종류

기본 PCA	중소 규모 데이터	메모리 용량 제약	높은 정확도, 직관적 분석 가능
점진적 PCA	초대형 데이터	학습 속도가 상대적으로 느림	메모리 절약, 배치처리 가능
랜덤 PCA	대형 데이터 (주성분 적음)	근사치 기반	속도가 매우 빠름
랜덤 투영	매우 대형 데이터	데이터 해석 불가	극강의 처리 속도, 거리 보존


3. 차원 축소 방법

MDS 다차원 스케일링



샘플간의 거리를 보존하면서 좌표 공간의 차원을 낮추는 것으로
고차원의 관계 정보를 저차원 좌표로 변환하는 과정을 의미
고차원 공간에서의 복잡한 거리 관계를 저차원으로 바꾸면서,
2차원 공간에 좌표로 찍히기는 하지만,
결과로 나온 x축과 y축 그 자체는 아무런 물리적 의미가 없음

t-SNE t-분포 확률적 임베딩



비슷한 샘플은 가까이, 비슷하지 않은 샘플은
멀리 떨어지도록 하면서 저차원을 축소
주로 시각화에 많이 사용되며, 특히 고차원에 있는 샘플의 군집을
시각화할 때 사용됨
모든 개체 간의 실제거리를 핵심 보존 대상으로 보는 MDS와 달리
가까운 이웃 간의 확률적 유사도를 핵심 보존 대상으로 봄
저차원 공간의 유사도는 t분포를 이용하여 측정