

NLP, 자연어 처리

쿠글 13기 남주혜

목차

01 NLP란?

02 데이터 전처리

03 텍스트 수치화

04 NLP 모델링

05 Transformer, GPT/Bert

06 최신 동향 및 마무리

01 NLP란?

NLP (Natural Language Process)

: 컴퓨터가 인간의 언어를 이해, 해석, 생성, 조작하도록 하는 기술

< 텍스트 이해 . 의도 파악 . 감정 분석 . 요약 . 기계 번역 . 음성 인식 >

오늘은 춥다 (단순 정보)

오늘 춥다니까 (감정 + 강조)

오늘 좀 춥다고? (되묻기)

→ **NLP** → 실제 의도와 의미를 컴퓨터가 파악

02 데이터 전처리

데이터 전처리: 텍스트 데이터를 분석하기 좋은 형태로 정리

토큰화: 문장을 단어로 분해

e.g.) "내일은 어버이날이다." → '내일', '은', '어버이날', '이다'

불용어 제거: 해석에 불필요한, 무의미한 단어 제거

e.g.) "나는 밥을 먹었다." → '밥', '먹다'

형태소 분석: 단어를 의미 단위로 분해

e.g.) "공부했습니다" → '공부', '하', '였', '습니다'

03 텍스트 수치화

텍스트 수치화: 컴퓨터는 문자를 직접 이해하지 못함. → 숫자 벡터로 변환

텍스트 수치화 방법

1. BoW (Bag of Words)
2. TF - IDF
3. Word2Vec

03 텍스트 수치화 - BoW

BoW (Bag of Words):

문장에서 단어가 몇 번 등장했는지를 기반으로 문장을 숫자로 표현하는 방법

단어의 순서와 문맥 < 출현 빈도 수

단순한 구조
빠른 계산 속도

단어 순서를 고려하지 않음
문맥 이해 불가능
단어 수가 많을 수록 벡터가 커짐

⇒ 자주 등장하지만 흔한 단어의 중요도는 낮추고,
특정 문서에서 중요한 단어에 더 높은 가중치를 부여해야 함.

03 텍스트 수치화 - TF-IDF

TF-IDF:

단어의 등장 횟수와 중요도를 함께 고려하여 텍스트를 숫자로 표현하는 방법

TF (단어의 출현 빈도) $\times$ IDF (희귀한 정도)

문서 1) 나는 축구를 좋아한다.

문서 2) 나는 농구를 좋아한다.

"나는", "좋아한다"

: 모든 문서에 자주 등장

→ 중요도 낮음

"축구", "농구"

: 특정 문서에서만 등장



→ 중요도 높음

03 텍스트 수치화 - Word2Vec

Word2Vec:

단어가 등장하는 문맥을 학습하여

의미가 비슷한 단어를 비슷한 벡터로 표현하는 임베딩 기법



04 NLP 모델링

NLP 모델링:

전처리와 수치화를 거친 텍스트 데이터를 이용해
컴퓨터가 언어의 패턴과 의미를 학습하도록 만드는 과정

초기 NLP 모델: 나이브 베이즈, svm, 로지스틱 회귀분석


→ 단어 순서 이해 못함, 긴 문맥 처리 한계

딥러닝 모델의 등장

: RNN, LSTM, seq2seq


04 NLP 모델링 - RNN

RNN: 이전 단어 정보를 다음 단계로 전달함으로써 문장의 흐름 학습 가능




04 NLP 모델링 - LSTM

LSTM: 중요한 정보를 오래 기억 가능함 → 긴 문장 처리 성능이 향상된 모델



04 NLP 모델링 - seq2seq

seq2seq: 입력 문장을 다른 문장으로 변환하는 모델




05 NLP 최신 동향

Attention 이란?

입력 시퀀스가 길어지면 출력 시퀀스의 정확도가 떨어지는 것을 보정해주기 위한 등장한 기법

RNN / LSTM

긴 문장을 하나의 벡터에 다 압축해서 기억함.
앞부분은 잊어버리고
중요한 단어가 뒤에 있으면 놓치기도 함.




Attention

문장 전체를 보면서
각각을 똑같이 보는 게 아니라
중요해 보이는 단어에 더 크게 집중하는 방법

05 NLP 최신 동향

Transformer

Attention 메커니즘을 기반으로 문장을 처리하는 모델



- **self-attention** : 문장 안에서 단어끼리의 관계를 파악

e.g) 철수가 사과를 먹었다. 그는 배가 고팠다.

→ "그"가 누구를 의미하는지 문맥으로 이해 가능

- 압도적인 학습 속도: RNN/LSTM처럼 순서대로 계산하지 않아도 됨

05 NLP 최신 동향

GPT Transformer의 Decoder 구조를 사용하는 생성형 언어 모델

- 문장을 왼쪽에서 오른쪽으로만 읽음
- 이전 단어를 기반으로 다음 단어 생성

Bert Transformer의 Encoder 구조를 사용하는 생성형 언어 모델

- 문장 전체를 동시에 읽고 문맥을 이해
- 문장 중 일부 단어를 가리고 예측하며 학습

05 NLP 최신 동향

LLM 대규모 텍스트 데이터로 학습한 초거대 언어 모델

- 방대한 지식 학습
- 다양한 작업 수행 가능
- 사람과 자연스러운 대화 가능